

LÉA DUBOIS

Ingénieure de recherche IA & Bioinformatique | NLP, Python, Biologie | Paris

lea.dubois@example.test | +33 6 00 00 00 02 | example.test/lea-dubois

Résumé

Ingénieure de recherche en bioinformatique spécialisée en NLP biomédical, machine learning et analyse de données omiques. Expérience dans la transformation de publications, données cliniques dé-identifiées et données transcriptomiques en modèles évalués, outils reproductibles et résultats interprétables pour des équipes scientifiques. Recherche un poste en IA appliquée aux sciences du vivant à partir d'octobre 2026.

Expérience

Institut BioNexus – Ingénieure de recherche, NLP biomédical

2024–2026

- Construction d'un pipeline Python d'ingestion et de normalisation de publications PubMed, avec annotation guidée par les ontologies MeSH et contrôle qualité des corpus.
- Fine-tuning de BioBERT sous PyTorch pour reconnaître gènes, pathologies et traitements, avec macro-F1 de 0,88, validation croisée et analyse d'erreurs avec les biologistes.
- Développement d'une API FastAPI de recherche sémantique et d'extraction d'entités, conteneurisée avec Docker et suivie par MLflow, DVC et GitHub Actions.
- Cadrage des besoins, protocoles d'évaluation et restitution des résultats auprès de chercheurs, bioinformaticiens et équipes produit dans un environnement international.

Genomic Systems Lab – Bioinformaticienne, stage de recherche

2023–2024

- Analyse de données single-cell RNA-seq : contrôle qualité, normalisation, réduction de dimension, clustering et identification de marqueurs avec Scanpy, Seurat et R.
- Production de notebooks reproductibles, visualisations scientifiques et synthèses bibliographiques pour interpréter les sous-populations cellulaires observées.

Projets

Extraction de relations biomédicales | Python, PyTorch, Transformers, BioBERT, spaCy

- Entraînement d'un pipeline NER et extraction de relations sur 4 200 résumés annotés, avec suivi des expériences, analyse d'erreurs par entité et interprétation des confusions.

Assistant RAG de littérature scientifique | Python, FastAPI, Qdrant, LangGraph, APIs LLM

- Développement d'un assistant sur des articles biomédicaux combinant recherche hybride, reranking, réponses sourcées et benchmark de questions conçu avec des utilisateurs scientifiques.

Analyse single-cell de réponses immunitaires | Python, Scanpy, R, Seurat, scVI

- Analyse reproductible de 18 000 cellules, de la qualité des données à l'annotation des clusters, avec comparaison de méthodes d'intégration et étude des voies biologiques différentielles.

Compétences

NLP & GenAI : PyTorch, Transformers, BioBERT, SciBERT, spaCy, NER, RAG, LangGraph

Bioinformatique : single-cell RNA-seq, Scanpy, Seurat, scVI, Biopython, BLAST, PubMed, MeSH

Machine Learning & statistiques : scikit-learn, XGBoost, classification, validation croisée, SHAP, expérimentation

Data & développement : Python, R, SQL, pandas, FastAPI, Docker, Git, MLflow, DVC, Linux

Formation

Université Paris-Saclay – Master Bioinformatique & Biostatistiques

2022–2024

Génomique, biologie des systèmes, statistiques, machine learning, traitement automatique du langage.

Université de Strasbourg – Licence Sciences de la vie

2019–2022

Biologie moléculaire, génétique, immunologie, programmation scientifique.

Publications & communication scientifique

Co-autrice d'un poster sur l'extraction d'entités biomédicales présenté à JOBIM 2025 | Animation de deux ateliers internes sur la reproductibilité des analyses et l'évaluation des modèles NLP.

Langues

Français natif | Anglais C1, rédaction scientifique | Allemand B1

Centres d'intérêt

Biologie marine | Médiation scientifique | Randonnée | Photographie microscopique